

YZM212 Makine Öğrenmesi Dersi

2. Laboratuvar Ödevi Raporu

Hasan Cömert
Öğrenci No: 24290056

15 Mart 2026

1 Teorik Çözümler

Likelihood (Olabilirlik) Fonksiyonu $L(\lambda)$ 'nın Yazılması

Elimizdeki veri setindeki $\{k_1, k_2, \dots, k_n\}$ her bir gözlemin birbirinden bağımsız ve aynı dağılıma sahip olduğunu varsayıyoruz. Poisson dağılımının olasılık kütle fonksiyonu (PMF) şu şekildedir:

$$P(k|\lambda) = \frac{e^{-\lambda} \cdot \lambda^k}{k!} \quad (1)$$

Tüm veri seti için Likelihood fonksiyonu $L(\lambda)$, n adet gözlemin olasılıklarının çarpımıdır:

$$L(\lambda) = \prod_{i=1}^n P(k_i|\lambda) = \prod_{i=1}^n \frac{e^{-\lambda} \cdot \lambda^{k_i}}{k_i!} \quad (2)$$

Çarpım işlemini basitleştirirsek:

$$L(\lambda) = \frac{e^{-n\lambda} \cdot \lambda^{\sum_{i=1}^n k_i}}{\prod_{i=1}^n k_i!} \quad (3)$$

Log-Likelihood $\ell(\lambda)$ Fonksiyonunun Türetilmesi

Çarpım işlemlerinin türevini almak zor olduğu için hesaplama kolaylığı sağlamak adına Likelihood fonksiyonunun doğal logaritması ($\ln$) alınır:

$$\ell(\lambda) = \ln(L(\lambda)) = \ln\left(\frac{e^{-n\lambda} \cdot \lambda^{\sum_{i=1}^n k_i}}{\prod_{i=1}^n k_i!}\right) \quad (4)$$

Logaritmanın çarpım, bölüm ve üs kurallarını uygulayarak ifadeyi açalım:

$$\ell(\lambda) = \ln(e^{-n\lambda}) + \ln\left(\lambda^{\sum_{i=1}^n k_i}\right) - \ln\left(\prod_{i=1}^n k_i!\right) \quad (5)$$

Nihai Log-Likelihood fonksiyonunu elde ederiz:

$$\ell(\lambda) = -n\lambda + \ln(\lambda) \sum_{i=1}^n k_i - \sum_{i=1}^n \ln(k_i!) \quad (6)$$

En İyi Parametre Tahmininin ($\hat{\lambda}_{MLE}$) Kanıtlanması

Log-Likelihood fonksiyonunun maksimum değerini bulmak için, λ 'ya göre birinci türevini alıp sifıra eşitleriz:

$$\frac{d\ell(\lambda)}{d\lambda} = \frac{d}{d\lambda} \left[-n\lambda + \ln(\lambda) \sum_{i=1}^n k_i - \sum_{i=1}^n \ln(k_i!) \right] \quad (7)$$

Son terimde λ olmadığı için türevi sıfırdır. Türevi alırsak:

$$\frac{d\ell(\lambda)}{d\lambda} = -n + \frac{1}{\lambda} \sum_{i=1}^n k_i = 0 \quad (8)$$

Bu noktadaki λ değeri en iyi tahmin olan $\hat{\lambda}_{MLE}$ 'dir. Denklemi çözelim:

$$n = \frac{1}{\hat{\lambda}_{MLE}} \sum_{i=1}^n k_i \quad (9)$$

$$\hat{\lambda}_{MLE} = \frac{1}{n} \sum_{i=1}^n k_i \quad (10)$$

Bu formül, verilerin aritmetik ortalamasıdır. Böylece $\hat{\lambda}_{MLE}$ değerinin aritmetik ortalama olduğu kanıtlanmıştır.

2 Grafiklerin Yorumlanması

Elde edilen grafikte mavi çubuklar gerçek trafik verisinin histogramını, kırmızı eğri ise bulduğumuz $\hat{\lambda}_{MLE} = 12.14$ parametresiyle oluşturulan Poisson modelini (PMF) göstermektedir.

Grafiğe göre, kırmızı eğrinin tepe noktası ile gerçek verinin yoğunlaştığı merkezin bir-biriyle tam eşleştiği görülmektedir. Model, verilerin yükseliş ve düşüş trendini başarıyla yakalamıştır. Özetle, incelenen trafik akışının Poisson dağılımına uygun olduğu varsayımı doğrulanmış ve hesaplanan model verilere yüksek bir uyum (fit) sağlamıştır.

3 Outlier (Aykırı Değer) Analizine Dair Teorik Tartışma


MLE Yönteminin Aykırı Değerden Etkilenmesi: Poisson MLE'si, verilerin aritmetik ortalamasına eşittir ($\hat{\lambda}_{MLE} = \frac{1}{n} \sum k_i$). Aritmetik ortalama, yapısı gereği tüm verilere eşit ağırlık verdiği için aykırı değerlere (outlier) karşı çok hassastır. Orijinal verimizin ortalaması $\lambda \approx 12.14$ iken, sete 200 gibi uç bir değer eklendiğinde yeni ortalama aniden $\lambda \approx 24.67$ 'ye fırlar. Tek bir hatalı veri, modelin yoğunluk tahminini iki katına çıkararak klasik MLE'nin ne kadar kırılgan olduğunu kanıtlar.

Belediye Planlamasındaki Riskler: Belediyenin bu hatalı modelle ($\lambda = 24.67$) hareket etmesi şu kritik sorunlara yol açar:

- **Gereksiz Yatırım:** İhtiyaç olmadığı halde maliyetli yol genişletme veya alt/üst geçit projelerine başlanarak devasa kamu kaynakları israf edilir.
- **Yanlış Sinyalizasyon:** Ana caddenin yeşil ışık süresi gereksiz uzatılarak, yan yollarda suni trafik sıkışıklığına sebep olunur.

Sonuç: İstatistiksel modeller körü körüne uygulanmamalıdır. Öncesinde mutlaka veri temizliği yapılmalı veya aykırı değerlere karşı dirençli (robust) alternatif istatistiksel yöntemler tercih edilmelidir.

Gerçek Trafik Verisi vs. Tahmin Edilen Poisson Modeli



Kaynaklar

- [1] Bishop, C. M. (2006). *Pattern Recognition and Machine Learning*. Springer. (Bölüm 2: Probability Distributions ve Maximum Likelihood)
- [2] Murphy, K. P. (2012). *Machine Learning: A Probabilistic Perspective*. MIT Press. (Bölüm 2.5: Poisson Distribution ve MLE)
- [3] YZM212 Makine Öğrenmesi Dersi 2025-2026 Bahar Dönemi, Ders Notları ve Laboratuvar Föyleri.